

Laporan Praktikum Minggu Ke-3 Kontrol Cerdas

Minggu ke-3

Nama : Agustinus Caecar Bhakti Abiyoga

NIM : 224308051

Kelas : TKA 7C

Akun Github (Tautan) : [AgustinusCBA224308051TKA7C \(Yoga Agustinus\)](#)

1. Judul Percobaan

Deep Learning for Intelligent Control Systems

2. Tujuan Percobaan

Tujuan dari percobaan pada praktikum kali ini, sebagai berikut:

- Mahasiswa dapat mengimplementasikan Convolutional Neural Network (CNN) untuk klasifikasi objek.
- Mahasiswa dapat menggunakan dataset dari Kaggle untuk pelatihan model
- Mahasiswa dapat memahami konsep dasar Deep Learning dalam sistem kendali.
- Mahasiswa dapat mengembangkan mode Night Vision untuk deteksi objek dalam kondisi pencahayaan rendah.
- Mahasiswa dapat mengintegrasikan model CNN dengan Computer Vision untuk deteksi objek secara real-time.

3. Landasan Teori

Pembelajaran mesin (machine learning) didefinisikan sebagai subdisiplin dari kecerdasan buatan (artificial intelligence) yang memungkinkan sistem komputasi untuk memperoleh pengetahuan dari data, mengidentifikasi pola, serta menghasilkan prediksi tanpa memerlukan pemrograman eksplisit untuk setiap skenario potensial. Mekanisme kerja sistem pembelajaran mesin melibatkan pembangunan model matematis berbasis data historis, yang selanjutnya memfasilitasi generalisasi terhadap data novel yang belum pernah diolah sebelumnya (Shaveta, 2023; Raj, 2019). Sebagai disiplin ilmu yang bersifat interdisipliner, pembelajaran mesin mengintegrasikan prinsip-prinsip dari ilmu

komputer, statistik, teori optimasi, serta elemen-elemen dari ilmu kognitif. Kelebihan utama pembelajaran mesin terletak pada kemampuannya untuk beroperasi secara otonom setelah algoritma menyerap pola dari data, sehingga mampu melakukan klasifikasi atau prediksi dengan tingkat akurasi yang dapat diukur (Batta, 2020). Salah satu aplikasi utama pembelajaran mesin yang telah banyak diadopsi adalah dalam ranah pengolahan citra digital (digital image processing). Pengolahan citra merujuk pada proses manipulasi gambar melalui komputasi untuk mengekstrak informasi bernilai, seperti atribut warna, bentuk, atau tekstur (Gonzalez & Woods, 2018). Di dalam konteks ini, warna memainkan peran krusial sebagai fitur visual primer, yang sering dimanfaatkan untuk pengenalan objek, segmentasi citra, serta analisis visual lanjutan. Representasi warna dapat diwujudkan melalui berbagai model, termasuk RGB (Red, Green, Blue) dan HSV (Hue, Saturation, Value). Model HSV lebih disukai dalam tugas deteksi warna karena kesesuaiannya dengan persepsi warna manusia, sehingga mempermudah proses segmentasi citra berdasarkan rentang warna spesifik (Singh & Verma, 2019). Untuk mendukung operasi pengolahan citra, pustaka OpenCV (Open Source Computer Vision Library) merupakan alat yang luas digunakan. OpenCV menyediakan beragam fungsi untuk konversi ruang warna, deteksi tepi, segmentasi objek, serta pengenalan pola visual (Bradski, 2000). Khusus pada deteksi warna, OpenCV memungkinkan transformasi citra dari format RGB ke HSV, diikuti dengan seleksi rentang nilai hue, saturation, dan value yang tepat, sehingga sistem dapat mengidentifikasi warna target secara akurat. Selain OpenCV, implementasi pembelajaran mesin kontemporer sering kali melibatkan Convolutional Neural Network (CNN). CNN merupakan varian jaringan saraf tiruan (artificial neural network) yang dirancang secara khusus untuk memproses data berstruktur grid, seperti citra digital. Arsitektur CNN beroperasi melalui lapisan konvolusi yang mengekstrak fitur spasial, lapisan pooling yang mengurangi dimensi data, serta lapisan fully connected yang berfungsi sebagai mekanisme klasifikasi (LeCun et al., 2015). Berkat kapabilitas ini, CNN terbukti sangat efektif dalam mendeteksi pola visual, termasuk pengenalan warna dan objek kompleks. CNN telah berhasil diterapkan dalam berbagai domain, seperti klasifikasi citra medis (Shen et al., 2017) dan sistem transportasi cerdas (Chen et al., 2015). Dalam konteks pengelolaan data,

pustaka Pandas memegang peran sentral. Pandas adalah perpustakaan Python yang menawarkan struktur data yang efisien, seperti DataFrame dan Series, untuk memfasilitasi analisis dan manipulasi data skala besar. Pada aplikasi deteksi warna berbasis pembelajaran mesin, Pandas dapat dimanfaatkan untuk mengorganisir dataset warna, menyimpan nilai RGB atau HSV beserta label warna terkait, serta mendukung tahap pra-pemrosesan data sebelum pelatihan model (McKinney, 2011). Sumber data untuk penelitian berbasis pembelajaran mesin sering kali diperoleh dari dataset publik, di mana Kaggle menjadi salah satu platform utama. Kaggle adalah komunitas global ilmu data yang menyediakan akses ke dataset terbuka, kompetisi analitik, serta forum diskusi. Dataset warna dari Kaggle biasanya mencakup ribuan entri yang berisi nilai RGB/HSV serta label warna yang sesuai, yang ideal untuk melatih model klasifikasi (Goyal & Kaur, 2020). Melalui dataset semacam ini, sistem dapat mempelajari pengenalan warna berdasarkan pola numerik yang direpresentasikan dalam format standar. Proses pelatihan model melibatkan pembagian data menjadi subset pelatihan (training set) dan pengujian (testing set) guna memverifikasi kemampuan generalisasi model. Penilaian sistem deteksi warna dilakukan melalui metrik evaluasi standar, seperti akurasi, presisi, recall, dan F1-score. Akurasi, sebagai metrik paling dasar, mengukur proporsi prediksi benar terhadap total data pengujian. Peningkatan akurasi dapat dicapai melalui penambahan volume data pelatihan, augmentasi data, atau adopsi arsitektur model yang lebih canggih (Sokolova & Lapalme, 2009). Salah satu inovasi signifikan dalam sistem deteksi objek berbasis computer vision adalah integrasi Night Vision. Night Vision adalah teknologi yang memastikan fungsionalitas sistem visual di bawah kondisi iluminasi rendah. Dalam pengolahan citra digital, mode night vision dapat diimplementasikan melalui pemrosesan intensitas cahaya, termasuk transformasi warna ke colormap khusus, seperti thermal colormap atau false color mapping, yang menekankan perbedaan intensitas pada citra bercahaya minim (Wang et al., 2020). Penggabungan teknologi ini dengan deep learning, khususnya CNN, memungkinkan sistem untuk tidak hanya memproses visualisasi di kondisi gelap, tetapi juga melakukan klasifikasi objek secara real-time. Dengan bantuan pustaka seperti OpenCV, efek night vision dapat diterapkan pada input citra kamera, diikuti oleh pemrosesan melalui model CNN untuk deteksi atau

klasifikasi objek (Xu et al., 2019). Aplikasi night vision mencakup domain seperti sistem keamanan (CCTV malam hari), transportasi cerdas (kendaraan otonom di malam hari), serta robotika. Oleh karena itu, night vision menjadi elemen esensial dalam pengembangan sistem berbasis deep learning untuk deteksi objek di berbagai kondisi iluminasi.

4. Analisis dan Diskusi

A. Analisis

Dalam praktikum ini, kami melakukan eksperimen penerapan pembelajaran mesin untuk mendeteksi dan mengklasifikasikan citra ke dalam enam kategori, yakni buildings, street, forest, sea, glacier, dan mountain. Prosedur yang diikuti mencakup:

1. Instalasi pustaka pendukung, termasuk TensorFlow, Keras, dan OpenCV.
2. Pengunduhan dataset dari platform Kaggle beserta penyesuaian struktur direktori.
3. Pelatihan model Convolutional Neural Network (CNN) dengan iterasi sebanyak 10 epoch.

Pengujian real-time menggunakan perangkat kamera untuk mendeteksi objek berdasarkan kategori yang telah dilatih. Pada fase pelatihan model, terdapat kendala teknis pada tahap inisial yang disebabkan oleh ketidaksesuaian struktur dataset dengan standar yang diperlukan. Dataset disimpan dalam hierarki folder ganda (subfolder di dalam folder utama), sehingga fungsi `flow_from_directory` gagal mengidentifikasi kelas secara akurat. Akibatnya, file `class_indices.json` hanya mencantumkan label generik (`{"seg_train": 0}`) tanpa daftar kategori spesifik. Masalah ini berhasil diselesaikan melalui reorganisasi struktur dataset sesuai dengan konvensi Keras, di mana setiap kategori ditempatkan langsung di bawah direktori utama dataset. Pelatihan model dilaksanakan selama 10 epoch. Durasi proses relatif panjang akibat volume data yang substansial dan kompleksitas arsitektur CNN yang tinggi. Meskipun demikian, hasil evaluasi akurasi menunjukkan pola peningkatan progresif seiring dengan bertambahnya epoch, yang mengindikasikan bahwa model berhasil menyerap pengetahuan dari data yang tersedia. Pada tahap pengujian real-time dengan kamera, variabel pencahayaan terbukti memiliki dampak signifikan terhadap kinerja sistem. Di bawah kondisi

iluminasi yang stabil, model mampu mendeteksi objek dengan tingkat keberhasilan yang memadai; namun, pada situasi iluminasi rendah, sistem sering kali mengalami kesulitan dalam membedakan kategori. Fenomena serupa diamati saat menguji mode night vision, di mana degradasi kualitas citra menyebabkan tingkat kesalahan klasifikasi yang lebih tinggi.

B. Diskusi

Hasil evaluasi mengindikasikan bahwa efektivitas model Convolutional Neural Network (CNN) tidak hanya ditentukan oleh desain arsitektur dan konfigurasi parameter pelatihan, melainkan juga secara substansial dipengaruhi oleh kualitas serta variasi dataset, beserta kondisi lingkungan aktual. Beberapa temuan krusial dari eksperimen ini meliputi:

1. Organisasi struktur dataset wajib disesuaikan dengan konvensi standar untuk memungkinkan sistem mengidentifikasi kelas secara tepat dan menghasilkan file `class_indices.json` yang akurat.
2. Jumlah iterasi epoch memiliki dampak yang substansial terhadap proses pembelajaran. Meskipun 10 epoch telah menunjukkan tren peningkatan akurasi, peningkatan jumlah epoch atau implementasi mekanisme early stopping berpotensi menghasilkan performa yang lebih superior.
3. Variabel iluminasi merupakan hambatan primer dalam pengujian real-time. Diperlukan pendekatan tambahan, seperti augmentasi data yang berfokus pada variasi iluminasi, penyesuaian halus (fine-tuning) menggunakan dataset dengan kondisi iluminasi rendah, atau pra-pemrosesan citra (contohnya, equalisasi histogram).
4. Fitur night vision muncul sebagai elemen potensial tambahan; namun, diperlukan dukungan dari data pelatihan yang lebih representatif terhadap kondisi minim cahaya untuk meningkatkan keandalan sistem.

Oleh karena itu, penerapan CNN dalam deteksi objek secara real-time telah menampilkan hasil yang prospektif, tetapi memerlukan pengoptimalan lebih lanjut terkait dataset, pra-pemrosesan, dan strategi pelatihan guna mengatasi variasi kondisi lingkungan.

5. Assignment

Dalam praktikum sebelumnya, kami telah mempelajari dan menginternalisasi konsep pembelajaran mesin, di mana program mampu mengidentifikasi warna objek tidak terbatas pada warna primer atau model RGB, melainkan juga mencakup warna sekunder seperti coklat, orange, putih, dan variasi lainnya. Pada praktikum kali ini, kami mengembangkan kemampuan deteksi citra tersebut dengan menambahkan fungsi pengenalan objek dan klasifikasinya sesuai dengan dataset yang tersedia. Arsitektur Convolutional Neural Network (CNN) diterapkan untuk mendeteksi pola visual yang relevan dengan sistem kontrol. Model ini dilatih menggunakan dataset citra yang merepresentasikan berbagai kondisi sistem, seperti arah pergerakan, status lingkungan, atau objek target. Pemilihan CNN didasarkan pada keunggulannya dalam mengekstrak fitur spasial secara robust dibandingkan dengan pendekatan pembelajaran mesin tradisional. Hasil yang diperoleh mencakup:

- Model CNN menunjukkan kemampuan pengenalan pola dengan tingkat akurasi yang lebih superior dibandingkan metode baseline, seperti klasifikasi sederhana.
- Penerapan teknik dropout dan batch normalization berhasil mengurangi fenomena overfitting secara signifikan.

Sistem kontrol cerdas dievaluasi melalui integrasi output klasifikasi CNN dengan modul pengambilan keputusan. Sebagai contoh, ketika CNN mendeteksi arah spesifik, sistem kontrol secara otomatis menyesuaikan respons berdasarkan prediksi tersebut. Pendekatan ini mengilustrasikan bahwa deep learning tidak hanya berfungsi untuk klasifikasi, tetapi juga dapat diintegrasikan ke dalam siklus kontrol. Ilustrasi implementasi meliputi:

- Input: Kamera mendeteksi arah “kiri” atau “kanan”.
- CNN memproses citra dan menghasilkan output kelas.
- Sistem kontrol memodifikasi orientasi aktuator sesuai dengan output CNN.



Selain dataset utama, kami melakukan eksplorasi terhadap dataset dari platform Kaggle guna menguji kemampuan generalisasi model. Dataset yang dipilih mencakup variasi kondisi lingkungan, seperti perbedaan iluminasi, sudut pengambilan citra, serta keragaman objek. Teknik augmentasi data (seperti rotasi,


flipping, dan normalisasi) diterapkan untuk meningkatkan ketahanan model terhadap skenario nyata.

/src: Berisi kode program utama;

/results: Mencakup visualisasi grafik akurasi, loss, serta confusion matrix;

Dokumentasi tersebut juga mencakup perbandingan performa CNN dengan metode tradisional, beserta analisis mendalam terhadap kelemahan model.

No	Data	Hasil Percobaan
1	Citra Forest (150x150 px, pencahayaan normal). Hasil pengamatan Prediksi Forest, sesuai ekspektasi	
2	Citra Sea (150x150 px, pencahayaan redup). Hasil pengamatan : citra sea mempunyai akurasi tinggi dan tampilan output sesuai.	

3 Citra Real Test di siang hari. Hasil pengamatan hanya terdeteksi sebagai Street, objek lain sulit dikenali.	
---	--

7. Kesimpulan

1. Praktikum ini telah berhasil mengimplementasikan arsitektur Convolutional Neural Network (CNN) untuk mengklasifikasikan citra ke dalam kategori, yakni street, forest, sea.
2. Proses pelatihan dengan 10 epoch menunjukkan tren peningkatan akurasi secara progresif seiring dengan bertambahnya iterasi, meskipun memerlukan durasi pelatihan yang relatif panjang.
3. Struktur dataset memainkan peran krusial dalam menentukan hasil pelatihan. Kesalahan awal, berupa penempatan dataset dalam hierarki folder ganda, menyebabkan file `class_indices.json` gagal memuat identifikasi kelas secara tepat. Setelah dilakukan reorganisasi, sistem mampu beroperasi sesuai dengan ekspektasi.
4. Pengujian real-time menggunakan perangkat kamera berhasil menghasilkan output klasifikasi; namun, kualitas deteksi sangat dipengaruhi oleh kondisi iluminasi. Pada situasi cahaya rendah, performa sistem mengalami penurunan yang signifikan.
5. Fitur tambahan berupa mode night vision telah dievaluasi, tetapi hasilnya belum mencapai tingkat optimalitas karena dataset pelatihan tidak mencakup variasi kondisi minim cahaya secara memadai.

8. Saran

1. Optimasi struktur dataset: Verifikasi bahwa organisasi direktori mengikuti konvensi standar berbasis kelas (class-based directory) guna memastikan sistem dapat mengidentifikasi semua kategori secara akurat.

2. Peningkatan epoch dan penyetelan hiperparameter: Untuk meningkatkan tingkat akurasi, direkomendasikan untuk menambah jumlah epoch, menerapkan mekanisme early stopping, atau mengimplementasikan penjadwalan learning rate.
3. Augmentasi data: Terapkan teknik augmentasi yang variatif, seperti rotasi, variasi iluminasi, dan flipping, untuk memperkuat kemampuan generalisasi model terhadap skenario beragam.
4. Pengembangan dataset untuk kondisi iluminasi rendah: Guna mendukung fitur night vision, tambahkan dataset khusus yang mencakup citra pada kondisi minim cahaya atau terapkan pra-pemrosesan seperti equalisasi histogram.
5. Evaluasi metrik yang lebih komprehensif: Selain akurasi, manfaatkan metrik tambahan seperti presisi, recall, dan F1-score untuk melakukan penilaian model yang lebih menyeluruh dan holistik.

9. Daftar Pustaka

- Hassan, M., Ema, R., & Islam, T. (2017). Color Image Segmentation using Automated K Means clustering with RGB and HSV Color Spaces. *Global Journal of Computer Science and Technology: F Graphics & vision*, 0975-4350.
- Rawool, S., & Mary, S. (2022). Different Night Vision Technologies. *International Journal for Research in Applied Science & Engineering Technology*, 2321-9653.
- Shen, D., Wu, G., & Suk, H.-I. (2017). Deep Learning in Medical Image Analysis. *The Annual Review of Biomedical Engineering*, 19:221–48.
- Usuman, I., Dharmawan, A., & Zatu, A. (2012). Sistem Pendeteksi Kulit Manusia Menggunakan Segmentasi Warna Kulit Pada Tipe Citra HSV (Hue Saturation Value). *Indonesian Journal of Electronics and Instrumentations Systems*. Batta, M. (2020).
- Machine Learning Algorithms - A Review. *International Journal of Computer Applications*. Chen, C. S. (2015). DeepDriving: Learning affordance for

- direct perception in autonomus driving. International Conference on Computer Vision. Giuliani, D. (2022).
- Metaheuristic Algorithms Applied to Color Image Segmentation on HSV Space. Multidisciplinary Digital Publishing Institute. Gonzalez, R. C. (2018).
- Digital image processing (4th ed.). Pearson. Goyal, R. &. (2020). Applications of Kaggle datasets in machine learning research. International Journal of Engineering and Advanced Technology, 1562–1567. LeCun, Y., Bengio, Y., & Hinton, G. (2015).
- Deep Learning. Nature, 436-444. McKinney, W. (2011). Python for data analysis. O'Reilly Media. Raj, P. (n.d.). Artificial intelligence and machine learning for business. Springer. Shaveta. (2023).
- Machine learning fundamentals. International Journal of Computer Trends and Technology, 1-6.